# HTML → BibTeX(ML)

#### Představení a motivace

BibTeX

BibTeXML

(strict X ext.)

Python 3

```
@MISC { someID,
  author = {Name Surname and
Another One },
  title = {Title Abc},
  year = \{2013\},
  note = {to appear, CHI} }
<br/><bibtex:file
xmlns:bibtex="http://bibtexml
.sf.net/">
<bibtex:entry id="someID">
<br/><bibtex:misc>
<br/><bibtex:author>Name Surname;
Another One</bibtex:author>
<br/><br/>bibtex:title>Title
Abc</bibtex:title>
```

## Seznámení...

Weby diametrálně odlišné

=> profily

Sekce neodpovídají BibTeX

=> odhad

Řádky si neodpovídají

=> rezignace

#### Hackování

přímo BibTeX – téměř nikde >95% citací – >1 zásadních chyb (<u>zad. BP</u>)

parser pro každý web/řádek – realita

python – regexpy nerad

XPath - záchrana?

## Řešení

Profil + trocha fuzzy + XPath prefix

unix-like batch chování (okamžitě chyba)

Ixml, BeautifulSoup

## Řešení – pokr.

locals() + bez tříd pojmenované argumenty + static look-behind regex precompile + simulace **Ixml close tags** BibTeX parser

## Zajímavosti

#### **BibTeXML**

```
# TODO try to distinguish between 'Name X.,' and 'Name, X.'
# impossible: Chambers, N., J. Allen, et al.
# possible?: Chambers, Nol., J. Allen,
# possible?: Chambers, Nolan, J. Allen,
# impossible: Allen, J. F. and C. R. Perrault
# impossible: Hinkelman, E. and J.F. Allen
# impossible: Traum, D. and Allen, J.F.
```

